8.2.2 线性回归的实现

2023 年 9 月 18 日

线性回归的 Python 实现

1. 相关性系数的实现

调用 scipy.stats.pearsonr 计算相关系数：

```
import scipy.stats as stats
r = stats.pearsonr(x1, x2)
```

也可以使用 pd.DataFrame.corr() 来计算相关系数矩阵，然后绘制图形，详细见下一节。

```
df = pd.DataFrame([(.2, .3), (.0, .6), (.6, .0), (.2, .1)],
                                columns=['dogs', 'cats'])
df.corr(method='pearson')
      dogs  cats
dogs   1.0   0.3
cats   0.3   1.0
```

2. 线性回归的实现

线性回归的 Python 实现主要使用 sklearn 机器学习库 linear_model 模块下的 LinearRegression 类。

```
class sklearn.linear_model.LinearRegression(*, fit_intercept=True, copy_X=True, n_jobs=None, po
```

类别	名称	含义
参数	**fit_intercept**	默认为 True，是否计算模型的截距，如果设为 False，是指数据是以原点为中心的，不会计算截距。
属性	**coef_**	线性回归问题的估计系数。

类别	名称	含义
	intercept_	线性模型中的独立项，也就是截距
方法	fit(X, y)	训练模型（或称估计器、学习器）
	predict(X)	在训练后，使用模型预测
	score(X, y)	用来计算模型的精度
	get_params()	获得模型的参数

模型输入 X 和 y

上述回归模型中使用 X 和 y 的数据结构如下，X 包含多个样本，以及每个样本的属性，也就是自变量，和 X 的每个样本对应的就是我们的预测目标 y，也就是因变量。

在实际编程中，一般使用 pd.DataFrame 来表示 X 和 y。

	自变量1	自变量2	自变量3
样本1			
样本2		X	
样本3			
...			

	因变量
样本1	
样本2	y
样本3	
...	

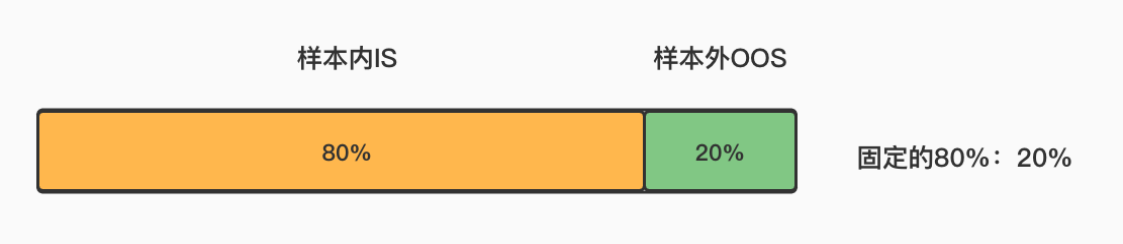

一般将 80% 的原始数据集的子样本集作为样本内 (In-sample, IS)，剩余 20% 作为样本外 (Out-of-sample, OOS)。样本总数为 500 个，一种简单的切割方法是直接指定前 400 个样本为 IS，后面为 OOS，但是这种采样方法存在弊端。

[19]:
```
train_x = X.values[:400]
train_y = y.values[:400]
```

```
test_x = X.values[400:]
test_y = y.values[400:]
```

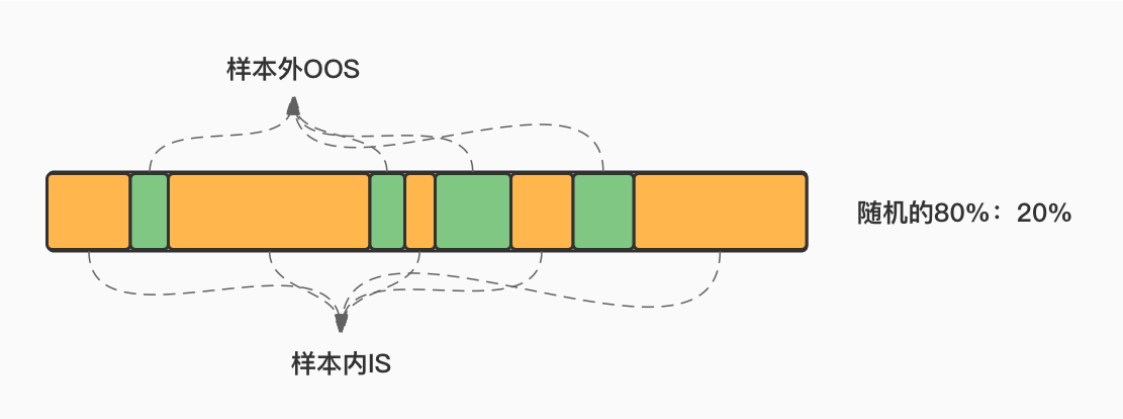

当我们并不了解原始数据集是不是被刻意排列了，最好的办法是使用随机抽样，即随机抽 80% 为 IS，剩余的 20% 为 OOS。使用 `sklearn.model_selection.train_test_split`

[20]:
```
from sklearn.model_selection import train_test_split
train_x, test_x, train_y, test_y = train_test_split(X, y,train_size=0.
↪8,random_state=42)
```

实现流程

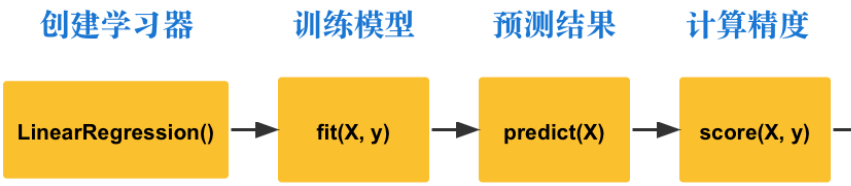

针对于多元回归分析，其一般化的流程如下：

1）创建学习器，也就是初始化线性回归模型

```
from sklearn.linear_model import LinearRegression
model = LinearRegression()
```

也可以这样表述：

```
from sklearn import linear_model
model = linear_model.LinearRegression()
```

2）训练模型

```
model.fit(X, y)
```

3）生成预测结果

```
predicted_y = model.predict(X)
```

4）计算模型预测精度和拟合优度 R^2

```
precision = model.score(X, y)
```

```
from sklearn.metrics import r2_score
r2 = r2_score(predicted_y, y)
```

5）生成汇总信息（summary）

```
print(" 系数: %s" %model.coef_)
print(" 截距: %.4f" %model.intercept_)
print(" 样本内 (IS) 训练集精度:%.2f" %precision)
print(" 拟合优度 R-squared: %.2f" % r2)
```

参考

1. sklearn 官网：链接